Laboratorio #13.2:

Laboratorio 13.2: Entrenamiento, experimentación con MLflow y dockerización del modelo

Objetivos:

- Convertir el código de experimentación del Data Scientist en un script de entrenamiento reproducible (src/models/train_model.py) configurado por YAML.
- Levantar MLflow con Docker Compose y registrar parámetros, métricas y el modelo de al menos dos ejecuciones comparables.
- Agregar el job model-training al pipeline de GitHub Actions, consumiendo los artefactos processed-data y featured-data y publicando el artefacto trained-model.
- Exponer el modelo entrenado como API REST con FastAPI (/health, /predict) y probarla localmente.
- Empaquetar la API en una imagen Docker y ejecutarla localmente como contenedor.

Guías de laboratorio:

- https://github.com/utec-devops-2026/laboratorios/blob/main/laboratorio_mlops/3.%20mlops-workflow-model-training-experimentation.md
- https://github.com/utec-devops-2026/laboratorios/blob/main/laboratorio_mlops/4.%20mlops-model-dockerization.md
- https://github.com/utec-devops-2026/laboratorios/blob/main/laboratorio_mlops/5.%20mlops-workflow-model-publish.md (solo la sección Job: model-training)

Alcance de esta sesión:

De la guía 5 solo se implementa el job model-training. El job build-and-publish y la publicación en Docker Hub son parte del laboratorio 14.1.

La imagen Docker se construye y ejecuta localmente; no se publica todavía.

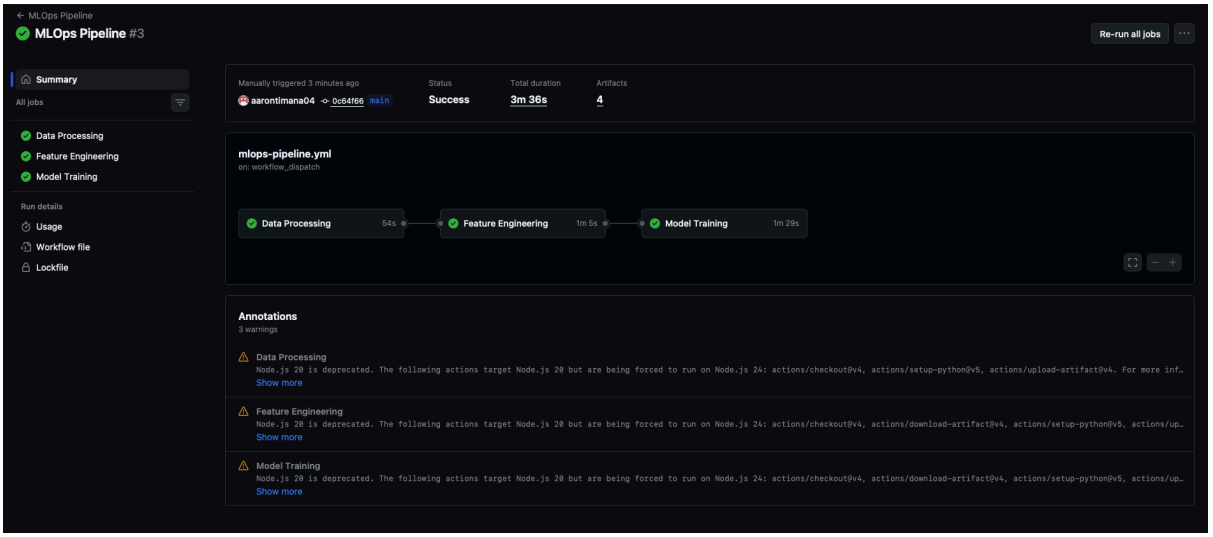
Entregables

1. **URL del repositorio de GitHub:** https://github.com/aarontimana04/mlops-lab-devops-lab13.1.git

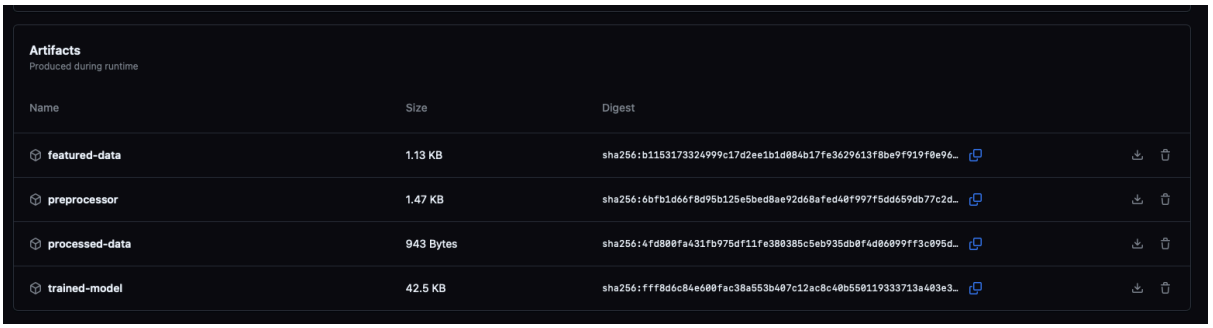
2. **Archivo de pipeline:** .github/workflows/mlops-pipeline.yml con los jobs data-processing, feature-engineering y model-training encadenados con needs.

3. **Archivos de la API y del contenedor:** src/api/main.py, src/api/schemas.py, src/api/inference.py y Dockerfile en la raíz del repositorio.

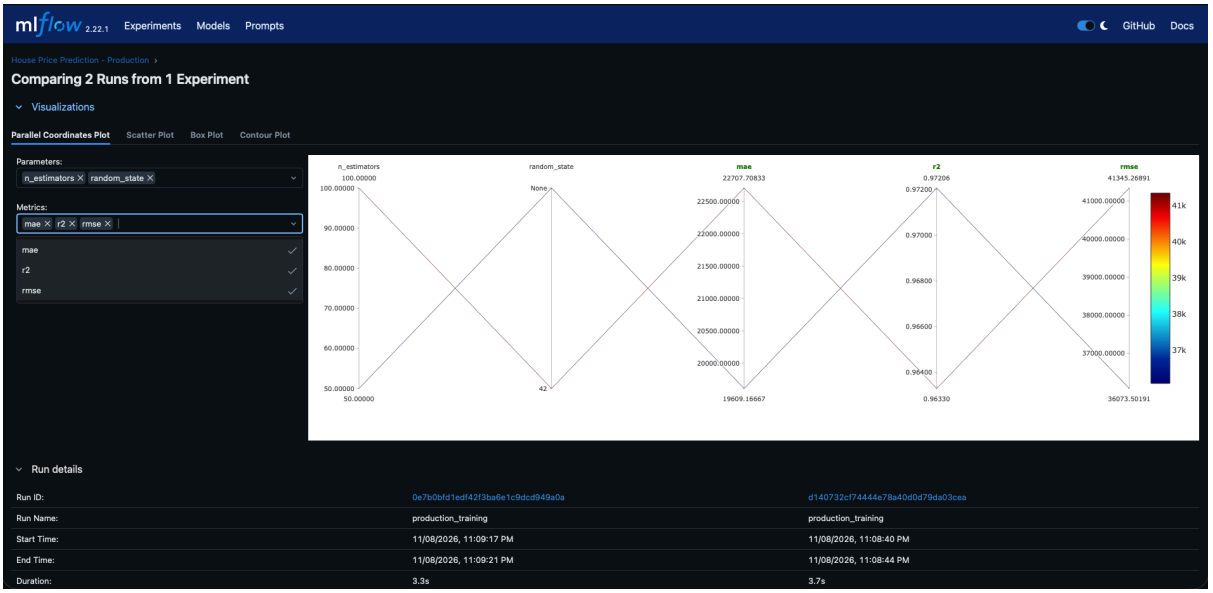
4. **Evidencias:**
    - El grafo de ejecución del pipeline en GitHub Actions mostrando los 3 jobs (Data Processing, Feature Engineering, Model Training) completados con éxito.



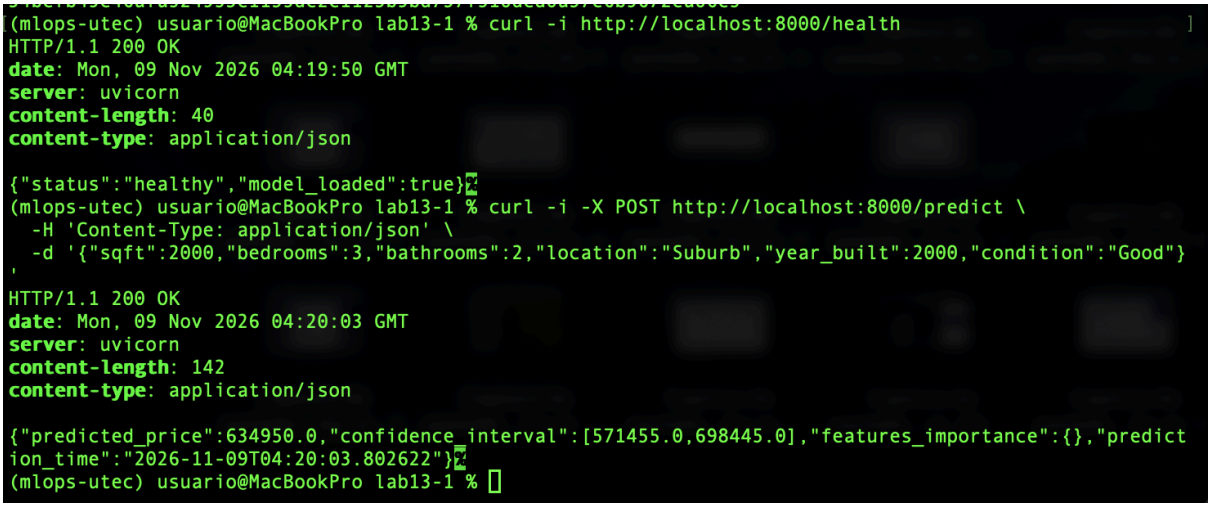
    - La sección "Artifacts" de la ejecución mostrando los cuatro artefactos: processed-data, featured-data, preprocessor y trained-model.



    - Captura de la UI de MLflow (http://localhost:5555) con al menos dos runs del experimento comparados (parámetros y métricas MAE, RMSE, R²)



- Ejecución del modelo con FastAPI desde la imagen Docker construida localmente: captura de Swagger (/docs) o de curl con la respuesta 200 de /predict.



Los comandos son:

```
docker build -t house-price-model:v1.0.0 .
docker run -d -p 8000:8000 --name house-price-api house-price-model:v1.0.0
curl http://localhost:8000/health
```